

农业中的计算机和电子产品

第 185 卷, 2021 年 6 月, 106133

原始论文

通过深度度量学习对个体荷斯坦-弗里西亚牛进行视觉识别

William Andrew ^{a, b}, Jing Gao ^b, Siobhan Mullan ^a, Neil Campbell ^b, Andrew W. Dowsey ^{a, c} ✉, Tilo Burghardt ^b

显示更多 ∨

☰ 大纲 | 🔗 分享 🗒 引用

<https://doi.org/10.1016/j.compag.2021.106133>

获取权利和内容

强调

- 个体牛识别的长期方法是侵入性的。
- 深度学习的进步允许强大的视觉检测和识别。
- 模型被证明可以推广到识别不用于训练的新个体。
- 倒数三元组损失和监督项的新组合表现最佳。
- 在精准农业中实现不干涉的牛跟踪和监控应用。

抽象的

荷斯坦-弗里西亚牛表现出独特的黑白外套图案，在视觉上类似于图灵的反应扩散系统产生的图案。这项工作利用这些自然标记，通过卷积神经网络和深度度量学习技术自动对个体荷斯坦-弗里斯兰牛进行视觉检测和生物特征识别。现有的方法依赖于具有各种维护要求的标记、标签或可穿戴设备，而我们提出了一种完全不干涉的方法，用于在开放的畜群环境中从头顶成像中自动检测、定位和识别个体动物，*即*无需重新培训即可识别牛群的新成员。我们发现，即使在系统训练期间要识别和重新识别许多看不见的牛时，深度度量学习系统也表现出强大的性能——实现93.8%仅对一半人口进行训练时的准确性。这项工作为促进牛的非侵入式监测铺平了道路，适用于精准农业和自动化生产力监测、健康和福利监测，以及行为分析、疾病爆发追踪等兽医研究。源代码、网络权重和基础数据集的关键部分是公开的（OpenCows2020）。

图形概要



[<](#) 上

下 [>](#)

关键词

自动化农业; 计算机视觉; 深度学习; 度量学习; 动物生物识别

1. 介绍

动机。受高产奶量驱动 (Tadesse 和 Dessie , 2003 年) , 黑白花纹荷斯坦-弗里西亚牛是最常见和分布最广的牛品种, 在 150 个国家/地区拥有约 7000 万头牲畜 (粮农组织乳制品生产和产品门户) 。图 1显示, 它们占北美 1000 万头奶牛的 89% 以上、欧洲 2100 万头奶牛的 63% 和澳大利亚和新西兰 600 万头奶牛的 42% (WHF 联合会 , 2020 年 , 食品 , 联合国 AO , 2020b) 。其他动物也可能有带图案的外套, 例如与荷斯坦弗里斯拉有关的动物, 如英国弗里斯拉, 以及它们的一些杂交品种, 例如在巴西生产 80% 牛奶的吉罗兰多, 巴西是第二大的国家奶牛数量 - 大约 1600 万头 (FAOSTAT 家畜初级) 。其他品种通常有带图案的外套, 例如诺曼德、短角和根西岛, 尽管这些品种还没有荷斯坦弗里西亚在全球的主导地位。此外, 许多有图案的皮毛动物, 尤其是雄性, 都是为了吃肉而饲养的。




图 1。牛品种分布。世界荷斯坦弗里西亚联邦 (WHF 联合会 , 2020 年) 报告的国家黑白荷斯坦和其他品种的数量。

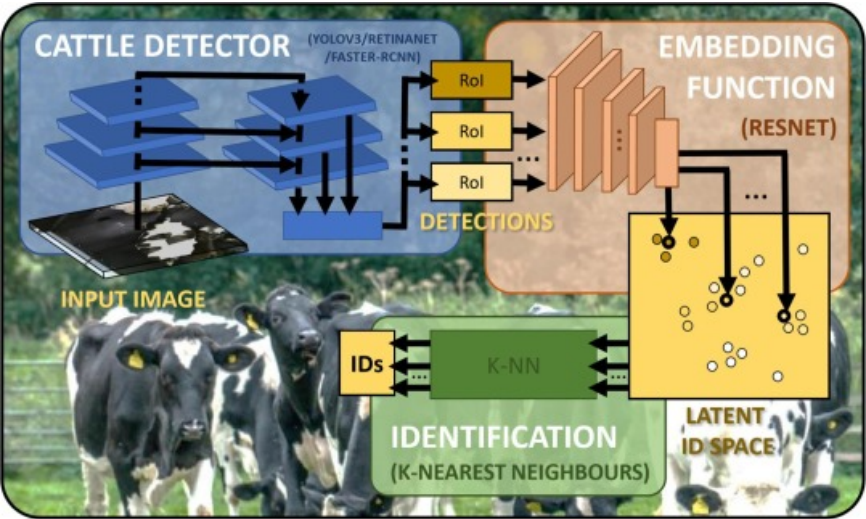
许多国家的法律框架要求对牲畜的整个生命周期进行追溯 (欧洲议会 , 1997 年 , 农业美元 (USDA) 动物 , 2018 年) , 以便识别个体以监测、控制疾病爆发等 (Hansen 等人 , 2018 年) , Smith 等人 , 2005 年 , Bowling 等人 , 2008 年 , Caporale 等人 , 2001 年) 。对于牛来说, 这通常以国家跟踪数据库的形式实现, 该数据库与每只动物的唯一耳标识别相关联 (休斯顿 , 2001 年 , 别克 , 2004 年 , Shanahan 等人 , 2009 年) , 或通过可注射转发器 (Klindtworth 等人) , 1999)、品牌推广 (Adcock et al , 2018) 等 (Awad , 2016) (见图2) 。然而, 这样的标签不能提供个体的持

前兆。-侵入式目视观察 (见图3) 。



[下载：下载高分辨率图片 \(425KB\)](#)
[下载：下载全尺寸图像](#)

图 2。牛识别方法。识别牛的传统方法示例。所有这些都依赖于一些物理添加，无论是永久性的（品牌、纹身、耳标）还是非永久性的（衣领）。相反，我们建议使用自然发生的涂层图案特征来从通过(d)无人驾驶飞行器(UAV)（顶部）或低成本静态相机（底部）获取的图像中实现基于视觉的识别。图片来源：(a) Velez 等人。(2013), (b)(Pennington, 2007), (c) PyonProducts, (d)(Bertram et al., 2006)。



[下载：下载高分辨率图片 \(389KB\)](#)
[下载：下载全尺寸图像](#)

图 3。识别管道概述。用于自动检测和识别已知和从未见过的牛的建议管道。该过程从一个品种范围的检测器开始，该检测器提取与个体模式无关的牛感兴趣区域 (RoI)。然后通过 ResNet 驱动的降维模型嵌入这些模型，该模型被训练为根据单个外套图案对图像进行聚类。然后可以通过轻量级方法（例如 k 最近邻）对投影到这个潜在 ID 空间的 RoI 进行分类，最终为输入图像生成牛的身份。只要模型已经学会了足够区分的减少，未知的牛就可以被投影到这个相同的空间中，这样它的新嵌入就可以根据距离与其他集群区分开来。

见过和训练过的个体，还应该能够识别和重新识别以前从未见过的牛，而无需进一步的再培训。为了提供一个完整的过程，我们提出了一个完整的管道，用于从图像输入到 ID 的检测和开放集识别（见图3）。

本文的其余部分及其贡献组织如下：第2节在本文的背景下讨论了相关的工作。接下来，第3节描述了与本文一起使用和发布的数据集。然后第4节概述了荷斯坦-弗里斯兰品种 RoI 检测，这是所提出的识别流程的第一阶段，随后是第5节中关于开放集个体识别的第二阶段，并对第6节中给出的各种相关技术进行了广泛的实验。最后，第7节给出了结束语和未来工作的可能途径。

2. 相关工作

早在 1922 年，我们的 Petersen 就发现了牛的口吻作为一种皮纹特征，牛生物识别技术最长期的方法就是利用这一发现。（彼得森，1922 年）。从那时起，这一特性以半自动方法的形式被利用（Kumar 和 Singh，2017 年，Kumar 等人，2017 年，Kimura 等人，2004 年，Tharwat 等人，2014 年）和那些在枪口图像（Awad 和 Hassaballah，2019 年，El Hadad 等人，2015 年，Barry 等人，2007 年）。然而，这些技术依赖于不容易获得的受严格限制的牛口吻图像的存在。其他工作着眼于视网膜生物识别（Allen 等人，2008 年）、面部特征（Barbedo 等人，2019 年、Cai 和 Li，2013 年）和身体扫描（Arslan 等人，2014 年），所有这些都需要专门的成像。

2.1. 自动牛生物识别

只有少数作品利用计算机视觉领域的进步，基于全身背部特征自动提取个人身份（Martinez-Ortiz 等人，2013 年，Li 等人，2017 年）。我们以前的作品利用了这一特性；利用在外套上提取的手动描述的特征（Andrew 等人，2016 年），类似于 Li 等人后来的工作。（2017），随后我们的深度学习方法优于我们使用卷积神经网络从整个图像序列中提取特征（Andrew et al., 2017, Andrew et al., 2019, Andrew, 2019），类似于（Hu et al., 2020 年, 乔等人，2019）。最近，有一些作品整合了牛脸的多个视图以进行识别（Barbedo 等人，2019 年），利用热图像进行背景减法作为基于 CNN 的标准分类管道的预处理技术（Bhole 等人，2019），并从无人机获取的图像中检测牛的存在（Barbedo et al., 2019）。在这项工作中，我们继续利用荷斯坦和荷斯坦-弗里斯兰品种表现出的皮毛图案的背部生物特征，因为它们可证明在种群之间提供了足够的区别。此外，可以通过静态天花板安装的摄像机或在户外使用无人机轻松获取图像。请注意，此类鸟瞰图像提供了对象的规范和一致的视点，遮挡的可能性被广泛消除，并且可以以非侵入方式捕获图像。

2.2. 深度物体检测

目标检测器通常分为两类：单级检测器，例如 SSD（Liu et al., 2016）和 YOLO（Redmon et al., 2016），它们在单个前馈网络中推断类别概率和边界框偏移量，和两阶段检测器，例如 Faster R-CNN（Ren et al., 2015）和 Cascade-RCNN（Cai and Vasconcelos, 2018），它们首先对图像进行预处理以生成与类别无关的区域，然后对这些区域进行分类并回归相关的边界盒子。以 YOLOv3（Redmon 和 Farhadi，2018 年）和 RetinaNet（Lin 等人，2017a 年）为例的单级检测器的最新改进）以单个检测阶段的一般速度提供与两阶段检测器相当的检测精度。在这项工作中，RetinaNet 架构被用作选择的检测网络，因为它还解决了类别不平衡问题；用焦点损失代替传统的交叉熵损失进行分类。

2.3. 开集识别

开放集识别问题——即自动重新识别从未见过的物体——是计算机视觉和机器学习中一个经过充分研究的领域。传统和开创性技术通常以概率和统计方法为基础（Jain 等人，2014 年，Scheirer 等人，2014 年，Rudd 等人，2017 年），替代方案包括专门的支持向量机（Scheirer 等人，2012 年），Mendes et al., 2016）和其他人（Bendale and Boulton, 2015，Mendes et al., 2017）。

然而，鉴于使用深度学习和神经网络技术（Sermanet 等人，2013 年，Girshick 等人，2014 年，Krizhevsky 等人，2012 年）在基准数据集上获得的性能提升，开放集识别的方法也随之而来。可以发现提出的深度模型在自动编码器范式中运行（Oza 和 Patel，2019 年，Yoshihashi 等人，2019 年），其中网络学习将输入图像转换为有效的潜在表示，然后从该表示中尽可能接近地重建它尽可能。最近的工作包括使用开放集损失函数公式代替 softmax（Bendale 和 Boulton，2016）、生成接近训练集的反事实图像以加强对象识别（Neal et al., 2018），以及结合这两种技术的方法（Ge et al., 2017，Shu et al., 2017）。Geng 等人讨论了一些额外但不太相关的技术。（2018 年）。


人, 2019 年, Masullo 等人, 2019 年) 并量化它们对开放式潜在空间的适用性。设置识别荷斯坦-弗里西亚牛。

3. 数据集：OpenCows2020

为了便于本文中进行的实验，我们介绍了公开可用的 OpenCows2020 数据集 (OpenCows2020)。该数据集由室内和室外自上而下的图像组成，汇集了多个先前的作品和数据集 (Andrew et al., 2016, Andrew et al., 2017, Andrew et al., 2019)。室内镜头是用静态固定的相机拍摄的，而室外图像是在无人机上拍摄的。该数据集分为下面详述的两个组件，用于 (a) 牛检测和定位，我们管道的第一阶段，以及 (b) 开放集识别，第二阶段。


3.1. 检测和定位

OpenCows2020 数据集的检测和定位组件由整个图像组成，这些图像在谷仓内和室外设置中具有手动注释的牛区域。当在这个集合上训练一个检测器时，一个人得到一个模型，该模型在环境方面是广泛的领域不可知论者，并且可以部署在各种与农业相关的条件下。数据集的这个组件共有 3,707 张图像，包含 6,917 条牛注释。对于每头奶牛，我们根据 VOC 2012 指南 (Everingham 等人, 2012 年) 手动注释了包围动物躯干的边界框，不包括头部、颈部、腿部和尾部。这是为了将内容限制在规范、紧凑且变形最小的物种相关区域。该集合的说明性示例在图 4。为了便于对这个数据集进行交叉验证，图像被随机打乱并分成 10 倍，比例为 8:1:1 分别用于训练、验证和测试。图 5 给出了每张图像的对象大小和对象数量的分布，其中显示了不同的数据集源；无人机采集的镜头包含更高比例的更小、更远的牛对象，而室内镜头通常包含更高分辨率的对象注释。



下载：下载高分辨率图片 (271KB) 下载：下载全尺寸图像

图 4。检测和定位数据集示例。示例实例说明了为执行全品种检测和牛定位的训练和测试模型提供的数据集的采集条件和环境的多样性。



下载：下载高分辨率图片 (104KB) 下载：下载全尺寸图像

图 5。检测数据集分布。(左) 注释对象区域的分布 (按来源分组)：(a) (Andrew 等人, 2019 年)，(b) (Andrew 等人, 2016 年) 和 (c) (Andrew 等人, 2017 年) 和 (右) OpenCows2020 数据集检测组件的每个图像的对象计数。


环境、照明条件等。每个类别的实例分布如图 6 所示。强调了三个数据源中存在的类别不平衡程度以及数据源本身内部的不平衡。



下载：下载高分辨率图片 (392KB)

下载：下载全尺寸图像

图 6。识别数据集示例。OpenCows2020 数据集中 46 个个体的示例实例，按来源分组 - (a) (Andrew et al., 2019), (b) (Andrew et al., 2016) 和 (c) (Andrew et al., 2017)。可观察的是采集方法、周围环境和背景、光照条件等方面的变化。




下载：下载高分辨率图片 (224KB)

下载：下载全尺寸图像

图 7。识别实例分布。OpenCows2020 数据集的识别组件每个类的实例分布。然后将实例随机拆分为每个类恰好有 10 个测试实例，而其余的实例分别以 9:1 的比例分为训练和验证。还标记了每组类别的来源：(a) (Andrew et al., 2019), (b) (Andrew et al., 2016) 和 (c) (Andrew et al., 2017)。

4. 牛检测

管道的第一阶段 (参见图 3, 蓝色) 是在相关图像中对荷斯坦-弗里西亚牛进行自动且稳健的检测和定位。也就是说，我们想要训练一个通用的品种范围的牛检测器，这样对于一些图像输入，我们会收到一组边界框坐标((



下载：下载高分辨率图片 (268KB)

下载：下载全尺寸图像

图 8。检测和定位示例。用于物体检测的（左）室内和（右）室外实例示例。（红色）“奶牛”类的矩形地面实况边界框和（蓝色）具有相关置信度分数的奶牛预测边界框。 (x_1, y_1) 和 (x_2, y_2) 分别是每个边界框的左上角和右下角坐标。（有关此图例中颜色参考的解释，请读者参考本文的网络版本。）

4.1. 检测损失

RetinaNet 由一个骨干特征金字塔网络 (Lin et al., 2017b) 和两个特定任务的子网络组成。一个子网络使用焦点损失对主干的输出执行对象分类，另一个子网络回归边界框位置。为了实现焦点损失，我们首先定义 p_t 为方便起见如下：

$$p_t = \begin{cases} p & \text{if } y = 1 \\ 1 - p & \text{otherwise} \end{cases} \quad (1)$$

在哪里 $y \in \{\pm 1\}$ 是ground truth, p 是 $y = 1$ 时的估计概率。对于检测，我们只需要将牛从背景中分离出来，因此会出现一个二元分类问题。因此，焦点损失定义为：

$$FL = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (2)$$

在哪里 $-\log(p_t)$ 是二元分类的交叉熵， γ 是平衡容易/困难样本的调制因子，并且 α 可以平衡正/负样本的数量。焦点损失函数保证训练过程首先关注正样本和困难样本。

回归子网络预测四个参数 $((P_{x_1}, P_{y_1}), (P_{x_2}, P_{y_2}))$ 表示偏移坐标 $((x_1, y_1), (x_2, y_2))$ 在anchor box A和ground-truth box Y之间。他们的真实偏移量 $((T_{x_1}, T_{y_1}), (T_{x_2}, T_{y_2}))$ 可以表示为：

$$\begin{aligned} T_x &= (Y_x - A_x)/A_w \\ T_y &= (Y_y - A_y)/A_h \end{aligned} \quad (3)$$

其中Y是ground-truth box, A是anchor box。边界框的宽度和高度由 w 和 h 给出。回归损失可以定义为：

$$L_{LOC} = \sum_{j \in \{x_1, y_1, x_2, y_2\}} \text{Smooth}_{L1}(P_j - Y_j) \quad (4)$$

其中 Smooth L1 loss 定义为：

$$\text{Smooth}_{L1}(x) = \begin{cases} 0.5x^2 & |x| < 1 \\ |x| - 0.5 & |x| \geq 1 \end{cases} \quad (5)$$

总体而言，检测网络最小化了组合损失函数，分别将与定位和分类相关的平滑 L1 和焦点损失分量结合在一起：

$$L_{LOC+FL} = L_{LOC} + \lambda \cdot L_{FL}, \quad (6)$$

在哪里 L_{LOC} 和 L_{FL} 由方程式定义。(4), (2)分别和 λ 是一个平衡参数。

4.2. 实验装置

了与其他基线进行适当的比较，两种流行的开创性架构——YOLOv3 (Redmon 和 Farhadi , 2018 年) 和 Faster R-CNN (Ren 等人 , 2015 年) ——经过交叉验证 (在相同的数据集和拆分上) 在下一节中。最终模型权重被选择为使用口袋算法在整个训练过程中在该折叠的验证集上表现最佳的模型权重 (Stephen , 1990) 。然后使用这些权重来评估相应测试集上的模型性能。

4.3 . 基线比较和评估

表 1 显示了通过 10 倍交叉验证提出的检测方法 with 经典和最近的方法进行的定量比较，而 RetinaNet 对训练的响应示例如图 9 所示。平均精度 (mAP) 作为选择的指标来定量比较性能，对于每个网络，通过曲线下的平均面积计算每个交叉验证折叠的精度召回。从表中可以看出，所有方法都在检测任务上实现了近乎完美的性能，因此都适用于手头的应用。具体的参数选择包括置信度分数阈值0.5，非最大抑制 (NMS) 阈值0.28，以及联合交集 (IoU) 阈值0.5. 虽然置信度和 IoU 阈值常用于目标检测，但我们特意选择了较低的 NMS 阈值，这在下一段中是合理的。

表 1。定量表现。在 OpenCows2020 数据集的检测组件上比较 10 倍交叉验证结果，其中平均精度计算为每个折叠的精度召回空间中曲线下的面积，并表示为所有折叠的平均平均精度 (mAP)，如以及每个网络的最小值和最大值。

	在 COCO 上进行预训练 (Lin 等人 , 2014 年)	在 ImageNet 上进行预训练 (Deng et al., 2009)	mAP (%) : [最小, 最大]
YOLO V3 (雷德蒙和法哈迪 , 2018 年)	否	是	98.4: [97.8, 99.2]
Faster R-CNN (Ren et al., 2015) - Resnet50 骨干网	是	否	99.6: [98.8, 99.9]
RetinaNet (Lin et al., 2017a) - Resnet50 骨干网	否	是	97.7: [96.6, 98.8]

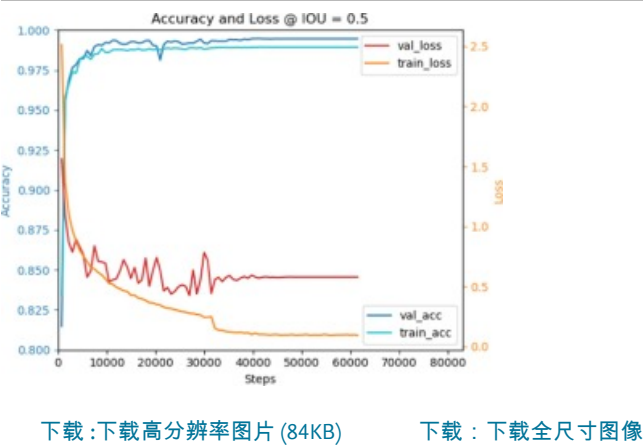



图 9。RetinaNet 训练图。在训练集和验证集上训练期间的 RetinaNet 损失和准确率值示例。

图 10 描述了限制并显示了很少发生的 RetinaNet 检测失败实例。示例 10 a 和 b 源于遵循 VOC 标记指南 (Everingham et al., 2012) 关于对象可见性/遮挡的图像边界裁剪，在大多数实际应用中可以通过忽略边界区域来避免这种情况。在 10.1



下载：下载高分辨率图片 (410KB)

下载：下载全尺寸图像

图 10. RetinaNet 的检测和定位失败。检测牛的罕见失败示例。(红色)：ground truth annotations，(蓝色)：预测的边界框。示例包括 (a) 图像边界处的假阳性检测，(b) 图像边界处的假阳性检测，(c) 假阳性检测，(d) 由于接近和对齐而导致的不准确定位和假阳性检测多头牛，(e) 由于多头牛的接近和对齐而导致的假阳性检测。(f) 描述了更高的示例 (0.5) NMS 阈值，它不足以使边界框消除其相邻的高置信度框。(有关此图例中颜色参考的解释，请读者参考本文的网络版本。)

我们选择将 NMS 阈值保持在尽可能低的水平，否则它偶尔会导致在具有拥挤牛群的图像中进行误报检测。图 10 f 描绘了 NMS 等于 0.5 而不是我们用于测试的值 (0.28) 的这种情况；当两只牛站得很近并且都有一个对角线方向时，有时可以观察到两只牛之间的预测框。这是由于使用正交边界框的内在缺点之一。

5. 通过度量学习的开集个体识别

给定包含牛的可靠识别图像区域，我们希望区分可见或不可见的个体，而无需手动标记新个体和完全重新训练封闭集分类器的昂贵步骤。完成这项任务的关键思想是学习一个映射到一个类别独特的潜在空间，在该潜在空间中，同一个人的图像映射自然地聚集在一起。这种特征嵌入对输入的潜在表示进行编码，对于图像，也相当于从矩阵显著降维 $width \times height \times channels$ 到具有大小的嵌入 \mathbb{R}^n ，其中 n 是嵌入空间的维数。在潜在空间中，距离直接编码输入相似性，因此称为度量学习。为了对输入进行实际分类，在构建成功的嵌入之后，可以将轻量级聚类算法应用于聚类现在代表个体的潜在空间（例如 k-Nearest Neighbours）。

5.1. 度量空间构建和损失函数

构建这种潜在表示形式的成功在很大程度上取决于（除其他因素外）对自然产生身份聚类空间的损失函数的仔细选择。度量学习中的一个开创性示例源于使用连体架构（Hadsell 等人，2006 年），其中图像对 X_1, X_2 通过具有耦合权重的双流网络获得它们的嵌入。重量 θ 在两个相同的网络流之间共享 f_θ ：

$$\begin{aligned} x_1 &= f_\theta(X_1), \\ x_2 &= f_\theta(X_2). \end{aligned} \quad (7)$$


作者建议根据类对集群实例进行对比损失来训练这种架构：

$$\mathcal{L}_{Contrastive} = (1 - Y) \frac{1}{2} d(x_1, x_2) + Y \frac{1}{2} \max(0, \alpha - d(x_1, x_2)), \quad (8)$$

其中 Y 是一个二进制标签，表示输入的相似性或不相似性 (X_1, X_2)，和 $d(\cdot, \cdot)$ 是维度为 n 的两个嵌入之间的欧几里得距离。这个公式的问题在于它不能同时鼓励学习视觉相似性和不同之处，这两者对于在我们的涂层图案区分任务中获得干净、分离良好的集群至关重要。这个缺点可以通过三重损失公式来克服（Schroff 等人，2015 年）；利用嵌入 x_a, x_p, x_n 包含三个图像输入的三元组 (X_a, X_p, X_n) 分别表示 anchor、来自同一类的正例和来自不同类的负例。这个想法是鼓励锚

说明了这个问题。最近的工作为 reciprocal triplet loss 的公式缓解了这一限制 (Masuno 等人, 2019 年), 它完全移除了边距超参数:

$$\mathbb{L}_{RTL} = d(x_a, x_p) + \frac{1}{d(x_a, x_n)}. \quad (10)$$



下载: 下载高分辨率图片 (142KB)

下载: 下载全尺寸图像

图 11. 三元组损失和保证金问题。(a)三元组损失函数旨在最小化anchor和positive实例 (都属于同一类) 之间的距离, 同时最大化anchor和negative (属于不同类) 之间的距离。但是, (b)说明了包含边距的问题 α 三重损失公式中的参数; 它可以在距锚点的任何距离处得到满足。

最近的工作 (Lagunes-Fortiz 等人, 2019 年) 通过在三元组损失公式中包含 SoftMax 项, 证明了对各种数据集 (Hodan 等人, 2017 年, Wang 等人, 2017 年) 的开放集识别的改进在培训期间:

$$\mathbb{L}_{SoftMax+TL} = \mathbb{L}_{SoftMax} + \lambda \cdot \mathbb{L}_{TL}, \quad (11)$$

在哪里

$$\mathbb{L}_{SoftMax} = -\log \left(\frac{e^{x_{class}}}{\sum_i e^{x_i}} \right), \quad (12)$$

和在哪里 λ 是一个恒定的加权超参数, 并且 \mathbb{L}_{TL} 是公式中定义的标准三元组损失。9. 对于我们的实验, 我们选择 $\lambda = 0.01$ 正如原始论文 (Lagunes-Fortiz 等人, 2019 年) 中所建议的那样, 作为参数网格搜索的结果。这个公式能够胜过标准的三元组损失方法, 因为它结合了两全其美——完全监督学习和可分离的嵌入空间。对于手头的任务, 最重要的是, 我们建议将由 Softmax 损失给出的完全监督损失项与倒数三元组损失公式结合起来, 从而消除了指定边际参数的必要性。这种组合是新颖的, 由以下给出:

$$\mathbb{L}_{SoftMax+RTL} = \mathbb{L}_{SoftMax} + \lambda \cdot \mathbb{L}_{RTL}, \quad (13)$$

在哪里 $\mathbb{L}_{SoftMax}$ 和 \mathbb{L}_{RTL} 由方程式定义。(10), (12)分别为。所有这些损失函数的比较结果在我们的实验中给出如下。


6. 实验

在下一节中, 我们比较和对比了不同的三元组损失函数, 以定量和定性地显示我们在荷斯坦-弗里西亚牛的开放集识别任务中的性能差异。这里进行的实验的目的是研究不同特征嵌入空间在多大程度上适合我们特定的开放集分类任务。在图 3 给出的整体识别流程的背景下, 我们将假设早期阶段 (如第4节所述) 已成功检测到牛的存在并提取了高质量的感兴趣区域。正如这些实验所评估的, 这些区域现在可以被识别。

6.1. 实验装置

置为初始学习率 1×10^{-5} 有动力 0.9 (钱, 1999) 和重量衰减 1×10^{-4} . 值得注意的是, 我们发现动量分量在训练过程中会导致显著的不稳定性, 并带有倒数的三元组损失, 因此我们在使用该函数的运行时禁用了它。最后, 对于选择作为另一个基线的比较封闭集分类器, 使用了相同的 ResNet50 架构。

一旦图像通过网络, 我们就获得了它的 n 维嵌入 x 。然后我们使用 k -NN 进行分类 $k=5$ 正如类似研究 (Lagunes-Fortiz 等人, 2019 年) 所建议的那样, 并通过参数搜索得到证实 (如图 12 所示)。使用 k -NN 对看不见的类进行分类的操作是将每个类中的每个非测试实例投影到潜在空间中; 在网络训练期间看到和未看到的。随后, 每个测试实例 (已知和未知个体的) 也被投射到潜在空间中。最后, 每个测试实例都是来自非测试实例的周围 k 个最近嵌入的投票中分类的。然后将准确度定义为正确预测的数量除以测试集的基数。



下载: 下载高分辨率图片 (76KB)

下载: 下载全尺寸图像

图 12. k -NN 参数搜索。为 k 个最近邻的不同选择对验证集的潜在表示进行分类时达到的准确度。此搜索是针对 50% 未解决的问题执行的。

为了验证模型从可见个体到不可见个体的泛化能力, 我们改变了完全从训练中保留的类的比例, 形成了未知集, $r = \{0.1, 0.17, 0.25, 0.33, 0.5, 0.6, 0.7, 0.8, 0.9\}$. 通过从每个图像源 (室内或室外, 参见第 3.2 节) 随机抽样, 按照各自的比率选择未知类, 以避免对背景或对象分辨率的偏差。在每个比率下, $n = 10$ 以这种方式随机生成重复, 以便在已知类别与未知类别的比率下建立更准确的模型性能图。通过改变这个比例, 我们研究了模型在一个日益开放的问题上的表现。重要的是, 这些 $|r| \times n$ 分裂在整个实验过程中保持不变, 以确保一致性并能够在实施的培训策略之间进行定量比较。

6.1.1. 身份空间挖掘策略

在训练过程中, 人们观察到网络学习很快, 因此, 大部分三元组变得相对缺乏信息。常用的补救措施是先验地挖掘三元组以获得困难的例子。这个离线过程被 Hermans 等人取代。在他们 2017 年的论文 (Hermans 等人, 2017 年) 中, 他们提出了两种在线方法来挖掘更合适的三元组, “batch hard”和“batch all”。在训练期间在每个小批量中挖掘三元组, 并根据选择计算它们的三元组损失。通过这种方式, 不再需要在训练之前进行昂贵的离线搜索。因此, 我们在这里采用“batch hard”作为我们的在线挖掘策略, 如下所示:

$$= \sum_{i=1}^P \sum_{a=1}^K \max \left(0, \overbrace{\max_{p=1 \dots K} d(x_a^i, x_p^i)}^{\text{hardest positive}} - \min_{\substack{j=1 \dots P; \\ n=1 \dots K; \\ j \neq i}} \overbrace{d(x_a^i, x_n^j)}^{\text{hardest negative}} + \alpha \right),$$

其中X是小批量三元组，P是锚类，K是这些锚的图像。这个公式总体上选择了适度的三元组，因为它们是每个小批量中最难的例子，而这又是训练数据的一小部分。我们将这种挖掘策略用于以下结果部分中给出的所有测试损失函数。


6.2 . 结果

表 2给出了我们实验的关键定量结果，图 13说明了与使用 Softmax 和交叉熵的标准封闭集基于 CNN 的分类基线相比，所实施的方法处理日益开放集问题的能力损失。正如人们所预料的那样，闭集方法与识别问题的开放程度（水平轴）具有线性关系；基线方法决不能通过设计推广到看不见的类。与此形成鲜明对比的是，可以看出所有基于嵌入的方法都大大优于实现的基线，证明了它们对手头问题的适用性。令人鼓舞的是，如图14所示，我们发现识别错误没有来自未知身份集的趋势。此外，我们发现网络并没有发现任何一个特定图像源（例如室内、室外）变得更困难的趋势，而是发现稍高比例的错误往往存在于动物/类别中，而实例，正如人们所期望的那样。

表 2。平均准确度。平均、最小和最大精度n = 10由 46 个个体组成的 OpenCows2020 数据集中不同比例的已知类别与未知类别的重复次数。这些结果也示于图13中。

		平均准确度 (%) : [最小值、最大值]								
已知/未知 (%)		90/ 10	83/ 17	75/ 25	67/ 33	50/ 50	40/ 60	30/ 70	20/ 80	10/ 90
验证	交叉熵 (闭集)	86.82 : [83.33, 90.67]	81.80 : [74.67, 86.22]	73.16 : [65.33, 78.67]	65.96 : [58.00, 76.22]	50.27 : [44.00, 54.89]	42.47 : [36.22, 51.78]	32.89 : [24.89, 41.78]	24.16 : [20.00, 29.78]	12.73 : [7.33, 16.89]
	Triplet Loss (Schroff 等人 , 2015 年)	92.97 : [91.35, 94.46]	93.13 : [91.80, 95.34]	94.08 : [92.24, 95.57]	93.33 : [90.69, 94.90]	90.91 : [88.91, 93.13]	89.48 : [85.59, 91.80]	86.78 : [80.49, 92.02]	84.26 : [76.27, 88.69]	77.49 : [72.06, 82.93]
	Reciprocal Triplet Loss (Masullo et al., 2019)	95.94 : [94.68, 97.34]	95.52 : [92.90, 97.78]	96.27 : [94.68, 97.34]	95.52 : [94.46, 96.45]	95.32 : [94.01, 96.67]	93.44 : [90.69, 95.34]	92.11 : [86.92, 94.90]	89.05 : [86.74, 93.35]	83.55 : [76.72, 89.58]
	Softmax + Triplet Loss (Lagues-Fortiz 等人 , 2019 年)	96.74 : [95.79, 98.23]	96.70 : [95.12, 98.67]	97.14 : [95.79, 98.23]	96.23 : [94.24, 97.56]	94.41 : [92.68, 95.12]	94.37 : [91.13, 96.23]	92.71 : [88.91, 94.90]	91.00 : [86.92, 92.90]	84.10 : [76.27, 89.36]
	(我们的) Softmax + Reciprocal Triplet Loss	96.54 : [95.79, 97.78]	96.61 : [95.79, 98.00]	96.90 : [95.57, 98.45]	95.61 : [94.90, 96.23]	94.68 : [92.46, 96.23]	94.66 : [92.46, 97.12]	92.13 : [89.58, 94.68]	90.95 : [89.14, 93.13]	83.64 : [78.27, 85.81]
测试	交叉熵 (闭集)	71.02 : [65.22, 79.78]	68.15 : [63.48, 80.43]	68.76 : [64.13, 74.78]	64.11 : [55.87, 71.30]	49.52 : [40.65, 54.78]	42.91 : [37.39, 46.74]	32.87 : [27.83, 35.87]	23.54 : [20.22, 27.39]	12.87 : [10.65, 14.78]
	Triplet Loss (Schroff 等人 , 2015 年)	80.37 : [77.01, 84.16]	81.28 : [78.31, 84.82]	84.38 : [78.96, 88.07]	85.23 : [79.39, 89.37]	83.67 : [76.36, 90.46]	82.67 : [78.52, 87.20]	83.06 : [74.84, 90.46]	81.65 : [72.67, 88.29]	78.76 : [67.03, 85.47]


Softmax + Triplet Loss (Lagunes-Fortiz 等人, 2019 年)	92.15 : [87.85, 97.18]	92 .73 : [86.77, 99.13]	95 .60 : [92.62, 98.26]	94.06 : [90.46, 97.18]	92.89 : [90.02, 96.10]	93 .88 : [91.54, 95.44]	91.80 : [88.72, 94.79]	90 .46 : [86.55, 92.84]	87 .79 : [80.48, 91.11]
(我们的) <i>Softmax</i> + <i>Reciprocal Triplet Loss</i>	92 .45 : [88.07, 97.18]	91.26 : [86.12, 96.10]	94.84 : [92.41, 97.83]	94 .36 : [91.32, 97.40]	93 .75 : [90.24, 95.66]	93.02 : [90.89, 94.58]	92 .49 : [90.46, 94.58]	90.22 : [87.64, 91.97]	87.55 : [83.51, 89.80]



[下载：下载高分辨率图像 \(306KB\)](#)

[下载：下载全尺寸图像](#)

图 13. 开集泛化能力。折叠的平均、最小和最大精度与问题的开放程度；即，在训练期间完全保留的所有身份类别的比例。绘制的是基于所采用的损失函数的不同响应，其中 TL 和 RTL 分别表示标准三元组损失和倒数三元组损失，“SoftMax +”表示交叉熵和三元组损失函数的加权混合，如[Lagunes-Fortiz 等人所建议的那样. \(2019 \)](#)。还包括一个基线，以突出传统封闭集分类器的不适用性。

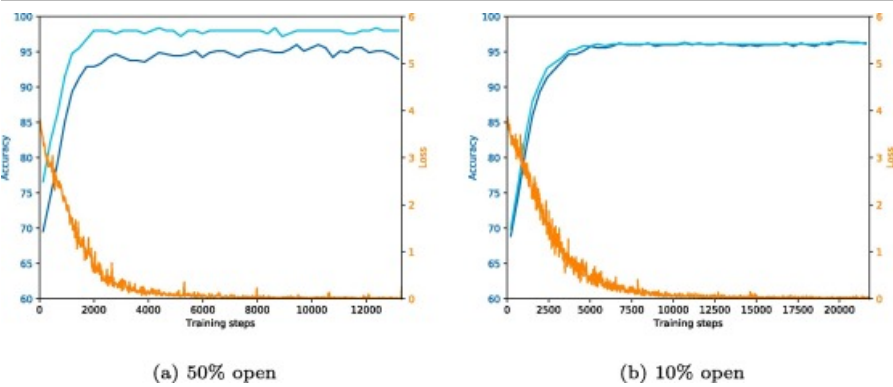


[下载：下载高分辨率图片 \(120KB\)](#)

[下载：下载全尺寸图像](#)

图 14. 错误比例与开放性。错误的比例在哪里（在已知或未知的集合中）与问题的开放程度。值是根据通过 Softmax 和倒数三元组损失训练的嵌入计算的。发现这些结果在所有使用的损失函数中都是一致的。

重要，这些身份排除了对新类的泛化。倒数三元组损失公式在整个学习任务中的表现略好，这在我们的研究结果中定量反映（见图13）。因此，我们建议在手头的任务中使用 RTL 而不是原始的三元组损失函数。




[下载: 下载高分辨率图片 \(194KB\)](#) [下载: 下载全尺寸图像](#)

图 15。培训验证准确性和损失。(a) 50% 开放问题和 (b) 10% 开放性的 100 个 epoch 训练过程中的训练和验证准确性示例。青色：训练准确率，蓝色：验证准确率，橙色：损失。（有关此图例中颜色参考的解释，请读者参考本文的网络版本。）

6.2.1 . 定性分析

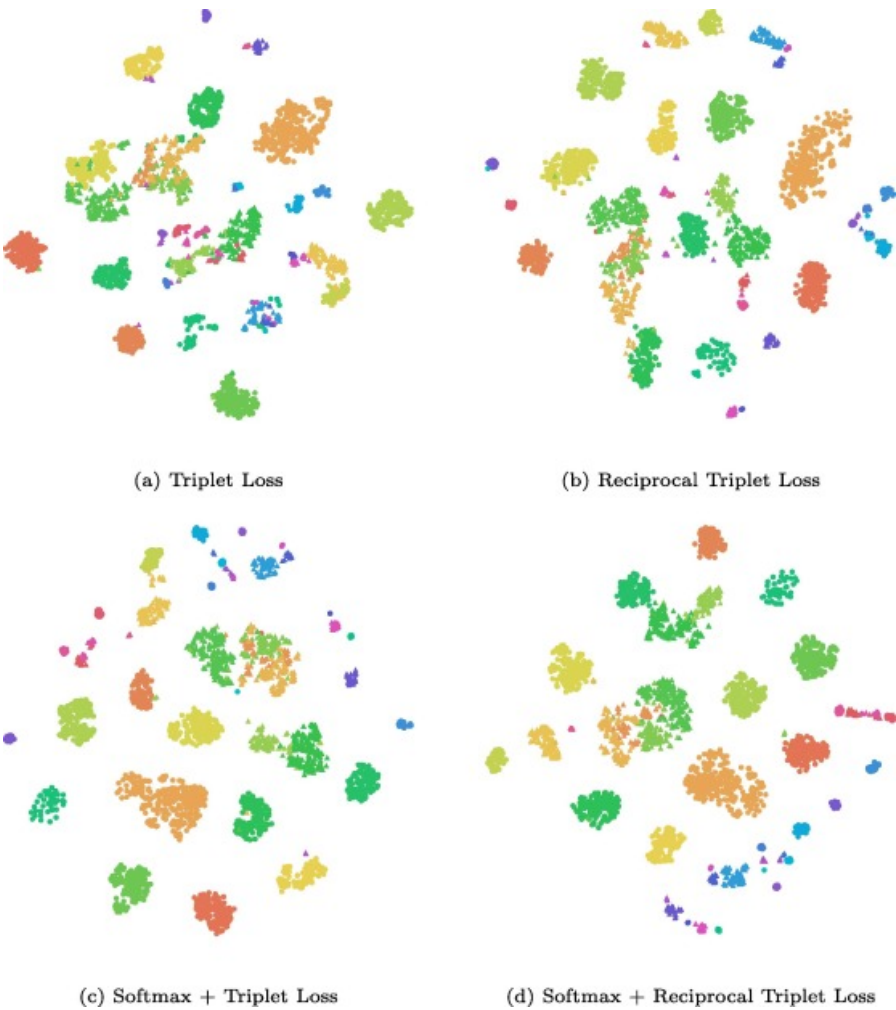
为了提供定性的可视化，我们包括图 16，它是嵌入空间和相应集群的可视化。该图和本节中的其他图是使用 t 分布随机邻域嵌入 (t-SNE) (van der Maaten 和 Hinton , 2008 年) 生成的，这是一种可视化高维空间的技术，困惑度为 30。可见——尤其是在与嵌入式训练集的关系（见图16）——是通过三元组损失公式训练的模型的成功，将相似的身份“聚集”在一起，同时疏远其他人。这足以进行聚类，从而重新识别从未见过的测试身份（参见图 16 c）。在这种情况下最重要的是，尽管只显示在训练期间一半的身份类别中，该模型学习了一个具有足够判别力的嵌入，可以很好地推广到以前看不见的牛。因此，令人惊讶的是，很少有涂层图案身份足以创建一个跨越维度的潜在空间，该空间可以成功地容纳和聚集看不见的身份。



[下载: 下载高分辨率图片 \(220KB\)](#) [下载: 下载全尺寸图像](#)

图 16。t-SNE (van der Maaten and Hinton , 2008) 嵌入可视化。每个类的训练、验证和测试实例的嵌入式空间示例。类标签的位置表示集群质心，红色的（ 23 个人；数据集的一半）表示在训练期间被保留的看不见的类。嵌入使用我们提出的损失函数进行训练，该损失函数将 Softmax 组件与倒数三元组损失相结合。（有关此图例中颜色参考的解释，请读者参考本文的网络版本。）

可分离的潜在表示。图 18 说明了覆盖在同一潜在空间中的每个类别的示例。这可视化了网络用来为训练期间看到的类生成可分离嵌入的空间相似性和不同点，这些类泛化到看不见的个体（以红色显示）。



下载 : 下载高分辨率图片 (469KB)

下载 : 下载全尺寸图像

图 17。每个损失函数的嵌入可视化。用于训练嵌入空间的各种损失函数的聚类可视化。这些可视化是针对所有损失函数中相同的 50% 未解决问题的第一折。请注意，代表不同类/动物的各个颜色在所有可视化中都是一致的。可视化是使用 t-SNE (van der Maaten and Hinton, 2008) 降维技术生成的。



下载: 下载高分辨率图片 (151KB)

下载: 下载全尺寸图像

图 18。类示例覆盖。从每个类中随机选择一个示例，覆盖在它们各自训练实例的嵌入的质心上，其中一半的类（以红色突出显示）在训练期间未显示。降维从 $n = 128$ 到 2 是使用 t-SNE (van der Maaten and Hinton, 2008) 执行的，并且嵌入是使用 Softmax 和倒数三元组损失进行训练的。（有关此图例中颜色参考的解释，请读者参考本文的网络版本。）

最后，本节中的实验依赖于从前一个检测阶段提供的优质牛区域的假设——考虑到检测任务的近乎完美的性能，这是一个合理的假设。在极少数情况下并非如此——可能是由于定位不佳或罕见的误报检测——绿色（用于户外图像）和其他背景像素的比例显著增加。因此，我们通常发现这种错误性质的图像嵌入远离潜在空间中的其他集群。因此，在这个空间选择一个距离参数将过滤掉绝大多数由这个问题引起的故障。

7. 结论

这项工作提出了一个完整的管道，用于在与农业相关的图像中识别单个荷斯坦-弗里西亚牛，无论是见过的还是以前从未见过的。对现有最先进的物体检测器的评估确定它们非常适合用作初始品种范围的牛检测器。在此之后，在开放集识别方面的广泛实验发现，学习和构建稳健的嵌入空间（从图像 RoI 到 ID 集群）所需的实例非常少，这可以很好地推广到看不见的牛。例如，对于使用 softmax 和倒数三元组损失由 46 个个体中的 23 个构建的潜在空间，平均准确度为 93.75% 被观测到。

在大多数国家，个体牛的识别是奶牛养殖的关键，而家禽等其他物种更可能被视为一个群体。饲养员通过监测每头奶牛的行为和健康状况获得的信息用于做出有关该动物的管理决策，包括与疾病预防和治疗、生育能力和喂养有关的决策。一些农场已经使用自动化的奶牛管理方法，例如通过计步器来检测可能表明发情行为的活动水平。对奶牛位置的个体识别和远程观察的一系列行为可以为疾病检测和福利监测提供重要的进一步精准农业机会，包括使用旨在为奶牛提供积极体验的资源。此外，有可能在更广泛的农场网络范围内（例如由公司或国家机构）对每个农场进行个体动物监测，以便及早发现疾病的爆发和传播。考虑到其更广泛的应用，我们的工作表明，拟议的管道是在牛群随时间动态变化的农业相关场景中以非侵入方式自动检测和识别牛的可行步骤。重要的是，识别组件可以在部署到当前牛群时进行训练，并且第一次如此处所示，在无需重新注册个人或随着人口变化重新训练系统的情况下表现良好 - 这是一个关键要求在实际农业环境中的可转移性。

7.1. 未来的工作

进一步的研究将着眼于通过连续重新识别从视频序列中进行跟踪。正如我们所展示的，我们的牛检测和个体识别技术非常准确，在视频帧之间结合简单的跟踪技术有可能过滤掉任何剩余的错误。这种方法对于大量挤奶的奶牛（例如，在传统挤奶厅挤奶之前）有多强大仍有待测试。

进一步的目标包括将碰撞检测用于分析社交网络和传播动力学，以及用于自动福利和健康评估的行为检测，这将允许纵向跟踪个体奶牛的疾病和福利状况。在这方面，需要评估在标准 RGB 旁边添加深度图像组件以支持和改进这些目标。

我们还将着眼于调查我们的方法在大量人群中的可扩展性。也就是说，通过额外的数据采集增加个体的基本数量，目的是学习荷斯坦-弗里西亚牛所表现出的背部特征的一般表示。这样一来，这为该模型在部署之前推广到新

项目管理、写作-审查和编辑。**Andrew W. Dowsey**：概念化、方法论、监督、项目管理、资金获取、写作评论和编辑。
Tilo Burghardt：概念化、方法论、监督、项目管理、写作-评论和编辑。

竞争利益声明

作者声明，他们没有已知的可能会影响本文报道的工作的竞争性经济利益或个人关系。

致谢

这项工作得到了 EPSRC 拨款 EP/N510129/1 下的艾伦图灵研究所和约翰奥尔德克基金会通过布里斯托兽医学校乳制品生产可持续发展和福利中心的约翰奥尔德克基金会的支持。我们感谢布里斯托兽医学校的 Suzanne Held、David Barrett 和 Mike Mendl 进行富有成效的讨论和提出建议，感谢 Kate Robinson 和温德赫斯特农场工作人员在数据收集方面的协助。还要感谢 Miguel Lagunes-Fortiz 允许使用、改编和重新分发关键源代码。

补充材料

以下是本文的补充数据：

 [下载：下载 XML 文件 \(1KB\)](#)

补充资料 1 .

[推荐文章](#) [引用文章 \(3\)](#)

本文的研究数据

OpenCows2020

原始数据

该数据集随附于论文“通过深度度量学习对个体荷斯坦弗里斯兰牛进行视觉识别”。它由两部分组成：（a）检测和定位，（b）识别。有关此数据集的概述，请参阅本文的第 3 节。如有任何疑问，请联系论文中的通讯作者。对于随附的源代码，请查看 -

<https://github.com/CWOA/MetricLearningIdentification>

[从布里斯托大学研究数据存储库获取数据](#) 

 [关于研究数据](#) 

参考

Adcock 等人，2018 年 SJ Adcock, CB Tucker, G. Weerasinghe, E. Rajapaksha

斯里兰卡坎塔莱四家乳品厂的品牌推广实践

动物, 8 (8) (2018), p. 137

 [查看 PDF](#) [交叉参考](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

艾伦等人，2008 A. 艾伦, B. 戈尔登, M. 泰勒, D. 帕特森, D. 亨里克森, R. 斯库斯

评估用于北爱尔兰牛生物特征识别的视网膜成像技术

牲畜科学, 116 (1-3) (2008), pp. 42 - 52

[文章](#)  [下载PDF](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

FEEDBACK 

安德鲁等人, 2016 W. 安德鲁、S. Hannuna、N. Campbell、T. Burghardt

通过 rgb-d 图像中的选择性局部外套图案匹配自动识别荷斯坦弗里西亚牛个体

2016 年 IEEE 国际图像处理会议 (ICIP) 论文集, IEEE (2016), 第484 - 488页

[查看 PDF](#) [交叉参考](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

安德鲁等人, 2017 W. 安德鲁、C. Greatwood、T. Burghardt

基于深度学习的荷斯坦奶牛视觉定位和个体识别

IEEE 计算机视觉国际会议论文集, IEEE (2017), 第2850 - 2859页

[交叉参考](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

安德鲁等人, 2019 W. 安德鲁、C. Greatwood、T. Burghardt

空中动物生物识别技术：通过具有机载深度推理的自主无人机恢复和视觉识别个体弗里斯兰牛

2019 年 IEEE/RSJ 智能机器人与系统国际会议 (IROS) 论文集, IEEE (2019), 第237 - 243页

[交叉参考](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

阿尔斯兰等人, 2014 AC Arslan, M. Akar, F. Alagöz

养牛场中的 3D 奶牛识别, IEEE (2014), 第1347 - 1350页

[交叉参考](#) [在 Scopus 中查看记录](#) [谷歌学术](#)

阿瓦德, 2016 艾阿瓦德 _

从经典方法到动物生物识别：牛识别与追踪综述

Comput. Electron. Agric., 123 (2016), pp. 423-435

[Article](#) [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

Awad and Hassaballah, 2019 A.I. Awad, M. Hassaballah

Bag-of-visual-words for cattle identification from muzzle print images

Appl. Sci., 9 (22) (2019), p. 4914

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

Balntas et al., 2016 V. Balntas, E. Riba, D. Ponsa, K. Mikolajczyk

Learning local feature descriptors with triplets and shallow convolutional neural networks, BMVA Press (2016), pp. 119.1-119.11

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

Barbedo et al., 2019 J.G.A. Barbedo, L.V. Koenigkan, T.T. Santos, P.M. Santos

A study on the detection of cattle in UAV images using deep learning

Sensors, 19 (24) (2019), p. 5436

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

Barry et al., 2007 B. Barry, U. Gonzales-Barron, K. McDonnell, F. Butler, S. Ward

Using muzzle pattern recognition as a biometric approach for cattle identification

Trans. ASABE, 50 (3) (2007), pp. 1073-1080

[View Record in Scopus](#) [Google Scholar](#)

Bendale and Boulton, 2015 A. Bendale, T. Boulton

Towards open world recognition

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE (2015), pp. 1893-1902

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

Bendale and Boulton, 2016 A. Bendale, T.E. Boulton

Towards open set deep networks

- [Bhole et al., 2019](#) A. Bhole, O. Falzon, M. Biehl, G. Azzopardi
A computer vision pipeline that uses thermal and rgb images for the recognition of holstein cattle
 International Conference on Computer Analysis of Images and Patterns, Springer (2019), pp. 108-119
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [Bowling et al., 2008](#) M. Bowling, D. Pendell, D. Morris, Y. Yoon, K. Katoh, K. Belk, G. Smith
Identification and traceability of cattle in selected countries outside of North America
 Profess. Anim. Sci., 24 (4) (2008), pp. 287-294
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- [Buick, 2004](#) W. Buick
Animal passports and identification
 Defra Vet. J., 15 (2004), pp. 20-26
[Google Scholar](#)
- [Cai and Li, 2013](#) Cai, C., Li, J., 2013. Cattle face recognition using local binary pattern descriptor. In: 2013 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference. IEEE, pp. 1–4.
[Google Scholar](#)
- [Cai and Vasconcelos, 2018](#) Z. Cai, N. Vasconcelos
Cascade R-CNN: Delving into high quality object detection
 Proceedings of the IEEE conference on computer vision and pattern recognition, IEEE (2018), pp. 6154-6162
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [Caporale et al., 2001](#) V. Caporale, A. Giovannini, C. Di Francesco, P. Calistri
Importance of the traceability of animals and animal products in epidemiology
 Revue Scientifique et Technique-Office International des Epizooties, 20 (2) (2001), pp. 372-378
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [Deng et al., 2009](#) Deng, J., Dong, W., Socher, R., Li, L.-J., Li, K., Fei-Fei, L., 2009. Imagenet: A large-scale hierarchical image database. In: 2009 IEEE conference on computer vision and pattern recognition. IEEE, pp. 248–255.
[Google Scholar](#)
- [Edwards and Johnston, 1999](#) D. Edwards, A. Johnston
Welfare implications of sheep ear tags
 Vet. Rec., 144 (22) (1999), pp. 603-606
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)
- [Edwards et al., 2001](#) D. Edwards, A. Johnston, D. Pfeiffer
A comparison of commonly used ear tags on the ear damage of sheep
 Anim Welf., 10 (2) (2001), pp. 141-151
[View Record in Scopus](#) [Google Scholar](#)
- [El Hadad et al., 2015](#) H.M. El Hadad, H.A. Mahmoud, F.A. Mousa
Bovines muzzle classification based on machine learning techniques
 Procedia Comput. Sci., 65 (2015), pp. 864-871
[Google Scholar](#)
- [European Parliament, 1997](#) European Parliament, 1997. Establishing a system for the identification and registration of bovine animals and regarding the labelling of beef and beef products and repealing council regulation (ec) no 820/97. <http://eur-lex.europa.eu/legal-content/EN/TXT/?uri=celex:32000R1760> (Online; accessed 2

- Food, A.O. of the United Nations, 2020a** Food, A.O. of the United Nations, 2020. Gateway to dairy production and products, <http://www.fao.org/dairy-production-products/production/dairy-animals/cattle/en/> (Online; accessed 4-August-2020).
[Google Scholar](#)
- Food, A.O. of the United Nations, 2020b** Food, A.O. of the United Nations, 2020. Faostat, <http://www.fao.org/faostat/en/#data/QL> (Online; accessed 4-August-2020).
[Google Scholar](#)
- Fosgate et al., 2006** G. Fosgate, A. Adesiyun, D. Hird
Ear-tag retention and identification methods for extensively managed water buffalo (Bubalus Bubalis) in Trinidad
Prevent. Vet. Med., 73 (4) (2006), pp. 287-296
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- Ge et al., 2017** Ge, Z., Demyanov, S., Chen, Z., Garnavi, R., 2017. Generative openmax for multi-class open set classification. arXiv preprint arXiv:1707.07418.
[Google Scholar](#)
- Geng et al., 2018** Geng, C., Huang, S.-J., Chen, S., 2018. Recent advances in open set recognition: A survey. arXiv preprint arXiv:1811.08581.
[Google Scholar](#)
- Girshick et al., 2014** R. Girshick, J. Donahue, T. Darrell, J. Malik
Rich feature hierarchies for accurate object detection and semantic segmentation
Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE (2014), pp. 580-587
[Google Scholar](#)
- Hadsell et al., 2006** Hadsell, R., Chopra, S., LeCun, Y., 2006. Dimensionality reduction by learning an invariant mapping. In: 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06), vol. 2. IEEE, pp. 1735-1742.
[Google Scholar](#)
- Hansen et al., 2018** M.F. Hansen, M.L. Smith, L.N. Smith, K.A. Jabbar, D. Forbes
Automated monitoring of dairy cow body condition, mobility and weight using a single 3D video capture device
Comput. Ind., 98 (2018), pp. 14-22
[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)
- Hassen and Chan, 2018** Hassen, M., Chan, P.K., 2018. Learning a neural-network-based representation for open set recognition. arXiv preprint arXiv:1802.04365.
[Google Scholar](#)
- He et al., 2016** K. He, X. Zhang, S. Ren, J. Sun
Deep residual learning for image recognition
Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE (2016), pp. 770-778
[Google Scholar](#)
- Hermans et al., 2017** Hermans, A., Beyer, L., Leibe, B., 2017. In defense of the triplet loss for person re-identification. arXiv preprint arXiv:1703.07737.
[Google Scholar](#)

Revue Scientifique et Technique-Office International des Epizooties, 20 (2) (2001), p. 652

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Hu et al., 2020](#) H. Hu, B. Dai, W. Shen, X. Wei, J. Sun, R. Li, Y. Zhang

Cow identification based on fusion of deep parts features

Biosyst. Eng., 192 (2020), pp. 245-256

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Jain et al., 2014](#) L.P. Jain, W.J. Scheirer, T.E. Boulton

Multi-class open set recognition using probability of inclusion

Proceedings of the European Conference on Computer Vision (ECCV), Springer (2014), pp. 393-409

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Johnston et al., 1996](#) A. Johnston, D. Edwards, E. Hofmann, P. Wrench, F. Sharples, R. Hiller, W. Welte, K. Diederichs

Welfare implications of identification of cattle by ear tags

Vet. Rec., 138 (25) (1996), pp. 612-614

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Kimura et al., 2004](#) A. Kimura, K. Itaya, T. Watanabe

Structural pattern recognition of biological textures with growing deformations: A case of cattle's muzzle patterns

Electron. Commun. Jpn. (Part II: Electronics), 87 (5) (2004), pp. 54-66

[View Record in Scopus](#) [Google Scholar](#)

[Klindtworth et al., 1999](#) M. Klindtworth, G. Wendl, K. Klindtworth, H. Pirkelmann

Electronic identification of cattle with injectable transponders

Comput. Electron. Agric., 24 (1-2) (1999), pp. 65-79

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Krizhevsky et al., 2012](#) Krizhevsky, A., Sutskever, I., Hinton, G.E., 2012. Imagenet classification with deep convolutional neural networks. In: Advances in neural information processing systems, pp. 1097-1105.

[Google Scholar](#)

[Kühl and Burghardt, 2013](#) H.S. Kühl, T. Burghardt

Animal biometrics: quantifying and detecting phenotypic appearance

Trends Ecol. Evol., 28 (7) (2013), pp. 432-441

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Kumar and Singh, 2017](#) S. Kumar, S.K. Singh

Automatic identification of cattle using muzzle point pattern: a hybrid feature extraction and classification paradigm

Multimedia Tools Appl., 76 (24) (2017), pp. 26551-26580

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Kumar et al., 2017](#) S. Kumar, S.K. Singh, R.S. Singh, A.K. Singh, S. Tiwari

Real-time recognition of cattle using animal biometrics

J. Real-Time Image Proc., 13 (3) (2017), pp. 505-526

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Lagunes-Fortiz et al., 2019](#) M. Lagunes-Fortiz, D. Damen, W. Mayol-Cuevas

Learning discriminative embeddings for object recognition on-the-fly

FEEDBACK 

Article  Download PDF View Record in Scopus Google Scholar

[Lin et al., 2014](#) T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, C.L. Zitnick

Microsoft COCO: Common objects in context

European conference on computer vision, Springer (2014), pp. 740-755

[CrossRef](#) [Google Scholar](#)

[Lin et al., 2017a](#) T.-Y. Lin, P. Goyal, R. Girshick, K. He, P. Dollár

Focal loss for dense object detection

Proceedings of the IEEE international conference on computer vision (2017), pp. 2980-2988

[Google Scholar](#)

[Lin et al., 2017b](#) T.-Y. Lin, P. Dollár, R. Girshick, K. He, B. Hariharan, S. Belongie

Feature pyramid networks for object detection, in

Proceedings of the IEEE conference on computer vision and pattern recognition (2017), pp. 2117-2125

[Google Scholar](#)

[Liu et al., 2016](#) W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, A.C. Berg

SSD: Single shot multibox detector

European Conference on Computer Vision, Springer (2016), pp. 21-37

[Google Scholar](#)

[Martinez-Ortiz et al., 2013](#) C.A. Martinez-Ortiz, R.M. Everson, T. Mottram

Video tracking of dairy cows for assessing mobility scores

<http://hdl.handle.net/10871/13481>

[Google Scholar](#)

[Masullo et al., 2019](#) A. Masullo, T. Burghardt, D. Damen, T. Perrett, M. Mirmehdi

Who goes there? exploiting silhouettes and wearable signals for subject identification in multi-person environments, in

Proceedings of the IEEE International Conference on Computer Vision Workshops (2019)

[Google Scholar](#)

[Mendes et al., 2016](#) Mendes Júnior, P.R., Boulton, T.E., Wainer, J., Rocha, A., 2016. Specialized support vector machines for open-set recognition. arXiv preprint arXiv:1606.03802.

[Google Scholar](#)

[Mendes et al., 2017](#) Mendes Júnior, P.R., de Souza, R.M., Werneck, R. d. O., Stein, B.V., Pazinato, D.V., de Almeida, W.R., Penatti, O.A., Torres, R. d. S., Rocha, A., 2017. Nearest neighbors distance ratio open-set classifier. Mach. Learn. 106(3), 359–386.

[Google Scholar](#)

[Meyer and Drummond, 2019](#) B.J. Meyer, T. Drummond

The importance of metric learning for robotic vision: Open set recognition and active learning

2019 International Conference on Robotics and Automation (ICRA), IEEE (2019), pp. 2924-2931

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Neal et al., 2018](#) L. Neal, M. Olson, X. Fern, W.-K. Wong, F. Li

Open set learning with counterfactual images

Springer (Ed.), Proceedings of the European Conference on Computer Vision (ECCV), Springer (2018), pp. 613-628

[View Record in Scopus](#) [Google Scholar](#)

FEEDBACK 

[Google Scholar](#)

[Oh Song et al., 2017](#) H. Oh Song, S. Jegelka, V. Rathod, K. Murphy

Deep metric learning via facility location

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE (2017), pp. 5382-5390

[Google Scholar](#)

[Opitz et al., 2018](#) M. Opitz, G. Waltner, H. Possegger, H. Bischof

Deep metric learning with bier: Boosting independent embeddings robustly

IEEE Trans. Pattern Anal. Mach. Intell., 42 (2) (2018), pp. 276-290

[Google Scholar](#)

[Oza and Patel, 2019](#) Oza, P., Patel, V.M., 2019. Deep CNN-based multi-task learning for open-set recognition. arXiv preprint arXiv:1903.03161.

[Google Scholar](#)

[Pennington, 2007](#) J.A. Pennington

Agriculture and Natural Resources: Tattooing of cattle and goats, University of Arkansas Cooperative Extension Service (2007)

[Google Scholar](#)

[Petersen, 1922](#) W. Petersen

The identification of the bovine by means of nose-prints

J. Dairy Sci., 5 (3) (1922), pp. 249-258

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Qian, 1999](#) N. Qian

On the momentum term in gradient descent learning algorithms

Neural Netw., 12 (1) (1999), pp. 145-151

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Qiao et al., 2019](#) Y. Qiao, D. Su, H. Kong, S. Sukkarieh, S. Lomax, C. Clark

Individual cattle identification using a deep learning based framework

IFAC-PapersOnLine, 52 (30) (2019), pp. 318-323

[Article](#)  [Download PDF](#) [CrossRef](#) [Google Scholar](#)

[Redmon and Farhadi, 2018](#) Redmon, J., Farhadi, A., 2018. Yolov3: An incremental improvement. arXiv preprint arXiv:1804.02767.

[Google Scholar](#)

[Redmon et al., 2016](#) J. Redmon, S. Divvala, R. Girshick, A. Farhadi

You only look once: Unified, real-time object detection

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), IEEE (2016), pp. 779-788

[Google Scholar](#)

[Ren et al., 2015](#) Ren, S., He, K., Girshick, R., Sun, J., 2015. Faster r-cnn: Towards real-time object detection with region proposal networks. In: Advances in neural information processing systems, 2015, pp. 91-99.

[Google Scholar](#)

[Robbins and Monro, 1951](#) H. Robbins, S. Monro

A stochastic approximation method

FEEDBACK 

[Google Scholar](#)

[Scheirer et al., 2012](#) W.J. Scheirer, A. de Rezende Rocha, A. Sapkota, T.E. Boulton

Toward open set recognition

IEEE Trans. Pattern Anal. Mach. Intell., 35 (7) (2012), pp. 1757-1772

[Google Scholar](#)

[Scheirer et al., 2014](#) W.J. Scheirer, L.P. Jain, T.E. Boulton

Probability models for open set recognition

IEEE Trans. Pattern Anal. Mach. Intell., 36 (11) (2014), pp. 2317-2324

[View Record in Scopus](#) [Google Scholar](#)

[Schroff et al., 2015](#) F. Schroff, D. Kalenichenko, J. Philbin

Facenet: A unified embedding for face recognition and clustering, in

Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, IEEE (2015), pp. 815-823

[CrossRef](#) [Google Scholar](#)

[Sermanet et al., 2013](#) Sermanet, P., Eigen, D., Zhang, X., Mathieu, M., Fergus, R., LeCun, Y., 2013. Overfeat: Integrated recognition, localization and detection using convolutional networks. arXiv preprint arXiv:1312.6229.

[Google Scholar](#)

[Shanahan et al., 2009](#) C. Shanahan, B. Kernan, G. Ayalew, K. McDonnell, F. Butler, S. Ward

A framework for beef traceability from farm to slaughter using global standards: an Irish perspective

Comput. Electron. Agric., 66 (1) (2009), pp. 62-69

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Shu et al., 2017](#) Shu, L., Xu, H., Liu, B., 2017. Doc: Deep open classification of text documents. arXiv preprint arXiv:1709.08716.

[Google Scholar](#)

[Smith et al., 2005](#) G. Smith, J. Tatum, K. Belk, J. Scanga, T. Grandin, J. Sofos

Traceability from a US perspective

Meat Sci., 71 (1) (2005), pp. 174-193

[Article](#)  [Download PDF](#) [View Record in Scopus](#) [Google Scholar](#)

[Stephen, 1990](#) I. Stephen

Perceptron-based learning algorithms

IEEE Trans. Neural Netw., 50 (2) (1990), p. 179

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Tadesse and Dessie, 2003](#) M. Tadesse, T. Dessie

Milk production performance of Zebu, Holstein Friesian and their crosses in Ethiopia

Livestock Res. Rural Develop., 15 (3) (2003), pp. 1-9

[Google Scholar](#)

[Tharwat et al., 2014](#) A. Tharwat, T. Gaber, A.E. Hassanien, H.A. Hassanien, M.F. Tolba

Cattle identification using muzzle print images based on texture features approach, in

Proceedings of the Fifth International Conference on Innovations in Bio-Inspired Computing and Applications IBICA 2014, Springer (2014), pp. 217-227

[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Turner et al., 2000](#) L. Turner, M. Udall, B. Larson, S. Shearer

FEEDBACK 

Rangeland Ecol. Manage., 58 (3) (2005), pp. 256-266

[Article](#)  [Download PDF](#) [CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[U.S.D. of Agriculture \(USDA\) Animal, 2018](#) U.S.D. of Agriculture (USDA) Animal, 2018. P.H.I. Service, Cattle identification, <https://www.aphis.usda.gov/aphis/ourfocus/animalhealth/nvap/NVAP-Reference-Guide/Animal-Identification/Cattle-Identification> (Online; accessed 14-November-2018).
[Google Scholar](#)

[van der Maaten and Hinton, 2008](#) van der Maaten, L.J., Hinton, G.E., 2008. Visualizing high-dimensional data using t-SNE. J. Mach. Learn. Res. 9(nov), 2579–2605.
[Google Scholar](#)

[Velez et al., 2013](#) J. Velez, A. Sanchez, J. Sanchez, J. Esteban
Beef identification in industrial slaughterhouses using machine vision techniques
Spanish J. Agric. Res., 11 (4) (2013), pp. 945-957
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Wang et al., 2017](#) X. Wang, F.M. Elliott, J. Ainooson, J.H. Palmer, M. Kunda
An object is worth six thousand pictures: The egocentric, manual, multi-image (emmi) dataset
Proceedings of the IEEE International Conference on Computer Vision (2017), pp. 2364-2372
[CrossRef](#) [View Record in Scopus](#) [Google Scholar](#)

[Wardrope, 1995](#) D. Wardrope
Problems with the use of ear tags in cattle
Vet. Rec., 137 (26) (1995), p. 675
[Google Scholar](#)

[W.H.F. Federation, 2020](#) W.H.F. Federation, 2020. Annual statistics. <http://www.whff.info/documentation/statistics.php> (Online; accessed 4-August-2020).
[Google Scholar](#)

[Yoshihashi et al., 2019](#) R. Yoshihashi, W. Shao, R. Kawakami, S. You, M. Iida, T. Naemura
开放集识别的分类重建学习, 在
IEEE 计算机视觉和模式识别会议论文集(2019), 第4016 - 4025页
[谷歌学术](#)

[查看摘要](#)

© 2021 Elsevier BV 保留所有权利。